

Universidad de Valparaíso

Magíster en Ciencias de la Ingeniería Biomédica

Estimación robusta de la función de respuesta hemodinámica en fMRI mediante redes neuronales informadas por la física

Autora: Valentinna Belén Montoya Aising
Asignatura: BME513 – Inteligencia Artificial en Salud
Profesor: Dr. Alejandro Veloz Baeza
Fecha: Julio de 2026

Repositorio: <https://github.com/Vale-Montoya/PINN-HRF-fMRI>

Presentación grabada: Pendiente de incorporar

Resumen

La función de respuesta hemodinámica (HRF) relaciona la actividad neuronal con la señal de contraste dependiente del nivel de oxigenación sanguínea (BOLD) observada mediante resonancia magnética funcional. En los análisis convencionales, esta respuesta suele representarse mediante una forma canónica fija, lo que puede limitar la capacidad de describir variaciones entre regiones, sesiones o sujetos. Este trabajo propone una red neuronal informada por la física (PINN) para estimar una HRF específica de la señal y parámetros efectivos del modelo Balloon–Windkessel. La formulación combina el ajuste a los datos con residuos de las ecuaciones diferenciales fisiológicas, condiciones iniciales de homeostasis y diferenciación automática. Para evaluar generalización, los parámetros inferidos en un bloque se introducen posteriormente en una integración numérica independiente del modelo, utilizada para predecir un segundo bloque no empleado durante el entrenamiento.

La validación sintética incluyó 60 instancias construidas a partir de cuatro escenarios, tres niveles de relación señal–ruido y cinco réplicas. La PINN alcanzó valores medios de R^2 fuera de muestra entre 0,984 y 0,992, y valores de R^2 para la recuperación de la HRF entre 0,983 y 0,992. En comparación con un modelo lineal general (GLM) y una red multicapa basada solo en datos (MLP), la PINN redujo de forma significativa los errores de reconstrucción y recuperación de la HRF.

La aplicación real utilizó datos de tarea motora del Human Connectome Project, sujeto 100206, con señales de la corteza motora primaria izquierda y derecha en corridas LR y RL. Se realizaron ocho evaluaciones bidireccionales entre bloques. La PINN obtuvo el menor RMSE medio fuera de muestra (0,502 puntos porcentuales BOLD) y ganó cuatro de ocho comparaciones. Sin embargo, las diferencias globales de RMSE no fueron significativas ($p = 0,223$). Sí se encontraron diferencias en correlación temporal ($p = 0,0076$), donde la PINN y la MLP superaron al GLM. La MLP presentó la mayor brecha entre entrenamiento y prueba, mientras que las HRF estimadas por la PINN mostraron alta consistencia en forma ($r = 0,958$).

Los resultados respaldan el uso de restricciones fisiológicas para mejorar la identificabilidad y generalización en condiciones controladas, aunque la aplicación real evidencia limitaciones asociadas a la variabilidad entre bloques, el tamaño muestral y la identificación de parámetros como τ . Los parámetros inferidos deben interpretarse como parámetros efectivos bajo los supuestos del modelo, y no como mediciones clínicas directas.

Palabras clave: fMRI, BOLD, HRF, PINN, Balloon–Windkessel, aprendizaje científico, problema inverso.

Índice

Resumen	i
1. Introducción	1
1.1. Pregunta de investigación	1
1.2. Objetivo general	1
1.3. Objetivos específicos	1
1.4. Contribuciones del trabajo	2
2. Fundamentos teóricos	2
2.1. Señal BOLD y función de respuesta hemodinámica	2
2.2. Modelo Balloon–Windkessel	2
2.3. Redes neuronales informadas por la física	3
3. Datos y preprocesamiento	3
3.1. Datos sintéticos	3
3.2. Datos fMRI reales	3
3.3. Regresión de confusores	4
4. Metodología propuesta	4
4.1. Diseño general	4
4.2. Función de pérdida	4
4.3. Parametrización acotada	5
5. Implementación computacional	5
5.1. GLM	5
5.2. MLP	5
5.3. PINN	5
5.4. Reproducibilidad y control de versiones	6
6. Diseño experimental y métricas	6
6.1. Validación sintética	6
6.2. Evaluación real bidireccional	6
6.3. Consistencia fisiológica	7
7. Resultados sintéticos	7

7.1. Reconstrucción fuera de muestra	7
7.2. Recuperación de la HRF	7
7.3. Recuperación de parámetros	8
7.4. Comparaciones estadísticas	9
8. Resultados en datos reales	9
8.1. Desempeño agregado	9
8.2. Pruebas estadísticas	9
8.3. Brecha de generalización	10
8.4. Consistencia de HRF y parámetros	10
8.5. Relación con la repetibilidad de los bloques	11
9. Discusión	11
9.1. Interpretación de la validación sintética	11
9.2. Interpretación de los datos reales	11
9.3. Identificabilidad	12
9.4. Limitaciones	12
9.5. Trabajo futuro	12
10. Conclusiones	12
A. Reproducibilidad	13

Índice de figuras

1.	Flujo de la PINN inversa con evaluación fisiológica fuera de muestra.	4
2.	RMSE de reconstrucción del segundo bloque sintético. Los puntos representan medias y las barras la variabilidad entre instancias.	7
3.	RMSE de recuperación de la HRF sintética.	8
4.	Error relativo de los parámetros fisiológicos inferidos por la PINN.	8
5.	RMSE fuera de muestra de GLM, MLP y PINN en las ocho direcciones reales. . .	9
6.	Brecha de generalización definida como RMSE de prueba menos RMSE de entrenamiento.	10
7.	Relación exploratoria entre repetibilidad de los bloques y error predictivo medio. .	11

Índice de cuadros

1.	Parámetros utilizados para generar las señales sintéticas.	3
2.	Configuración principal de la PINN utilizada en el lote real.	6
3.	Desempeño medio de la PINN en datos sintéticos.	7
4.	Rendimiento fuera de muestra en los ocho experimentos reales.	9
5.	Pruebas de Friedman en datos reales.	10

1. Introducción

La resonancia magnética funcional (fMRI) permite estudiar cambios asociados a la actividad cerebral mediante la señal BOLD. Esta señal no mide directamente la descarga neuronal, sino que refleja una respuesta vascular y metabólica con dinámica temporal propia. Por ello, el análisis de fMRI requiere un modelo que relacione el estímulo experimental con la respuesta hemodinámica observada.

El enfoque más utilizado es el modelo lineal general, en el cual los eventos se convolucionan con una HRF canónica y luego se ajustan a la señal observada. Esta representación ha sido fundamental para el análisis de fMRI, pero supone una forma temporal común que no necesariamente captura variaciones locales o individuales [2, 3]. Además, se han descrito no linealidades y efectos de saturación que pueden limitar la aproximación de convolución lineal en determinados paradigmas [4].

Una alternativa consiste en representar explícitamente la dinámica neurovascular mediante el modelo Balloon–Windkessel, que describe la evolución del flujo sanguíneo, volumen venoso y contenido de desoxihemoglobina [1, 4]. Sin embargo, estimar sus estados y parámetros a partir de una señal BOLD ruidosa corresponde a un problema inverso potencialmente mal condicionado.

Las redes neuronales informadas por la física incorporan ecuaciones diferenciales en la función de pérdida, combinando observaciones con conocimiento mecanístico [5]. En este proyecto se estudia si esta estrategia permite estimar una HRF y parámetros efectivos con mayor robustez que un GLM y una MLP puramente basada en datos.

1.1. Pregunta de investigación

¿Puede una PINN que incorpore el modelo Balloon–Windkessel estimar la respuesta hemodinámica y predecir bloques BOLD no utilizados durante el entrenamiento con mayor robustez e interpretabilidad que un GLM canónico y una MLP sin restricciones fisiológicas?

1.2. Objetivo general

Desarrollar y evaluar una PINN inversa para estimar la HRF y parámetros efectivos del modelo Balloon–Windkessel a partir de señales fMRI BOLD, comparando su desempeño con un GLM y una MLP en datos sintéticos y reales.

1.3. Objetivos específicos

1. Implementar el modelo Balloon–Windkessel y generar señales sintéticas con parámetros conocidos y ruido estructurado.
2. Diseñar una PINN que combine error de datos, residuos fisiológicos y condiciones iniciales.
3. Comparar GLM, MLP y PINN mediante evaluación fuera de muestra y recuperación de la HRF.
4. Aplicar el método a datos motores del Human Connectome Project.

5. Analizar la consistencia de la HRF y de los parámetros inferidos, además de sus limitaciones.

1.4. Contribuciones del trabajo

La contribución principal es una metodología de validación en dos niveles. Primero, se comprueba la recuperabilidad de la HRF y de parámetros conocidos en un entorno sintético. Segundo, se evalúa generalización real mediante entrenamiento y prueba en bloques distintos. Esta separación evita confundir un buen ajuste dentro de muestra con identificación fisiológica o capacidad predictiva.

2. Fundamentos teóricos

2.1. Señal BOLD y función de respuesta hemodinámica

La señal BOLD depende de cambios en flujo sanguíneo, volumen vascular y concentración de desoxihemoglobina. La HRF resume la respuesta temporal observada después de una entrada neuronal breve. En un modelo lineal, la señal esperada puede expresarse como

$$y(t) = (u * h)(t) + \varepsilon(t), \quad (1)$$

donde $u(t)$ representa el estímulo, $h(t)$ la HRF y $\varepsilon(t)$ el término de error. El GLM utiliza esta relación para construir regresores y estimar amplitudes de activación [2].

2.2. Modelo Balloon–Windkessel

Se utilizaron cuatro estados normalizados: señal vasodilatadora $s(t)$, flujo de entrada $f(t)$, volumen sanguíneo venoso $v(t)$ y contenido de desoxihemoglobina $q(t)$. La dinámica implementada fue

$$\dot{s}(t) = \epsilon u(t) - \kappa_s s(t) - \kappa_f [f(t) - 1], \quad (2)$$

$$\dot{f}(t) = s(t), \quad (3)$$

$$\tau \dot{v}(t) = f(t) - v(t)^{1/\alpha}, \quad (4)$$

$$\tau \dot{q}(t) = \frac{f(t)}{E_0} \left[1 - (1 - E_0)^{1/f(t)} \right] - v(t)^{1/\alpha} \frac{q(t)}{v(t)}. \quad (5)$$

La salida BOLD fraccional se calculó mediante

$$y(t) = V_0 \left[k_1(1 - q(t)) + k_2 \left(1 - \frac{q(t)}{v(t)} \right) + k_3(1 - v(t)) \right]. \quad (6)$$

El modelo captura transitorios como sobreimpulso y undershoot postestímulo, además de la interacción entre flujo, volumen y oxigenación [1, 4].

2.3. Redes neuronales informadas por la física

Una PINN aproxima los estados mediante una red neuronal diferenciable y penaliza el incumplimiento de las ecuaciones gobernantes. Dado un conjunto de tiempos de colocación $\{t_j\}$, la pérdida física se construye con residuos obtenidos por diferenciación automática. Esta estrategia permite abordar problemas directos e inversos sin discretizar explícitamente todas las variables latentes [5].

En este trabajo, ϵ , τ y α se trataron como parámetros entrenables acotados. Los restantes parámetros fisiológicos se mantuvieron fijos para reducir la no identificabilidad.

3. Datos y preprocesamiento

3.1. Datos sintéticos

Las señales sintéticas se generaron integrando el sistema Balloon–Windkessel con parámetros verdaderos conocidos:

Cuadro 1: Parámetros utilizados para generar las señales sintéticas.

Parámetro	Valor
ϵ	0,15
κ_s	0,65
κ_f	0,41
τ	0,98
α	0,32
E_0	0,34
V_0	0,02

Se añadió ruido estructurado compuesto por 50 % de ruido blanco, 35 % de ruido autorregresivo AR(1) y 15 % de deriva lenta. Se evaluaron niveles SNR 10, 5 y 2. El diseño completo incluyó cuatro escenarios, cinco réplicas y tres niveles de ruido, totalizando 60 señales.

La respuesta de referencia se definió operacionalmente como la respuesta del mismo sistema a un evento estandarizado de 1 s. Debido a la naturaleza no lineal del modelo, esta respuesta se utilizó como referencia comparable y no como una función impulso estricta en sentido lineal.

3.2. Datos fMRI reales

Se utilizaron datos de tarea motora 3T del Human Connectome Project, sujeto 100206, corridas MOTOR_LR y MOTOR_RL. El HCP proporciona adquisiciones multimodales y protocolos de preprocesamiento estandarizados [6, 7]; la tarea motora forma parte del conjunto de paradigmas task-fMRI descritos en el estudio de tarea fMRI del HCP [8].

Cada corrida contiene 284 volúmenes, con TR de 0,72 s y resolución isotrópica de 2 mm. Se extrajeron señales en torno a coordenadas MNI de la corteza motora primaria izquierda $(-38, -22, 56)$ y derecha $(38, -22, 56)$.

Los cuatro escenarios fueron:

- MOTOR_LR, M1 izquierda, condición mano derecha;
- MOTOR_LR, M1 derecha, condición mano izquierda;
- MOTOR_RL, M1 izquierda, condición mano derecha;
- MOTOR_RL, M1 derecha, condición mano izquierda.

3.3. Regresión de confusores

Para cada escenario se construyó un modelo de nuisance con las condiciones no objetivo, 12 regresores de movimiento, términos de deriva y constante. El ajuste se realizó fuera de las ventanas objetivo y posteriormente se sustrajo la contribución estimada. Dentro de cada ventana se utilizó la mediana del periodo preestímulo como línea base, evitando extrapolar una tendencia lineal que pudiera deformar la respuesta.

4. Metodología propuesta

4.1. Diseño general




Figura 1: Flujo de la PINN inversa con evaluación fisiológica fuera de muestra.

La formulación final se diseñó después de un piloto en el que la red aproximaba simultáneamente toda la trayectoria temporal. Aunque los residuos físicos eran bajos, la red podía representar amplitudes diferentes en bloques repetidos. Para evitar esta solución blanda, la formulación definitiva separó la inferencia de parámetros de la predicción: la PINN se ajusta en una ventana de entrenamiento y la evaluación se realiza mediante integración numérica independiente de las ODE.

4.2. Función de pérdida

La pérdida total se definió como

$$\mathcal{L} = \lambda_d \mathcal{L}_{\text{datos}} + \lambda_p \mathcal{L}_{\text{física}} + \lambda_i \mathcal{L}_{\text{inicial}} + \lambda_t \mathcal{L}_{\text{terminal}}. \quad (7)$$

El término de datos penaliza la diferencia entre BOLD observado y predicho. La pérdida física suma los residuos cuadráticos de las cuatro ecuaciones diferenciales. Las condiciones iniciales imponen homeostasis: $s = 0$ y $f = v = q = 1$. El término terminal favorece el retorno hacia la línea base al final de la ventana.

4.3. Parametrización acotada

Los parámetros se representaron mediante transformaciones sigmoides para garantizar los límites:

$$0,03 \leq \epsilon \leq 0,35, \quad (8)$$

$$0,50 \leq \tau \leq 2,00, \quad (9)$$

$$0,15 \leq \alpha \leq 0,60. \quad (10)$$

Estas cotas estabilizan la optimización y evitan regiones no fisiológicas, pero también condicionan la interpretación de los parámetros resultantes.

5. Implementación computacional

El proyecto se implementó en Python y PyTorch. La diferenciación automática permitió calcular derivadas temporales de los estados aproximados y gradientes de los parámetros entrenables [9]. El repositorio contiene notebooks reproducibles, código modular del modelo Balloon–Windkessel, métricas, pruebas estadísticas y pruebas unitarias.

5.1. GLM

El GLM sintético utilizó una HRF canónica tipo SPM. En datos reales, el diseño incluyó seis regresores de tarea, 12 regresores de movimiento, tres términos de deriva y una constante. Las métricas de generalización se calcularon sobre el bloque retenido.

5.2. MLP

La MLP utilizó como entrada una historia temporal del estímulo y dos capas ocultas con activación hiperbólica. Este modelo no contiene estados fisiológicos ni restricciones diferenciales, por lo que funciona como referencia puramente basada en datos.

5.3. PINN

La red de estados contiene tres capas ocultas de 64 neuronas con activación tanh y precisión de 64 bits. El entrenamiento se realizó en dos fases con Adam, seguido de L-BFGS. La primera fase priorizó la estabilización de los estados; la segunda incrementó el peso de los residuos físicos y optimizó conjuntamente los parámetros.

Cuadro 2: Configuración principal de la PINN utilizada en el lote real.

Elemento	Configuración
Capas ocultas	$64 \times 64 \times 64$
Activación	tanh
Precisión	float64
Adam fase 1	1.200 épocas
Adam fase 2	3.500 épocas
L-BFGS	hasta 300 iteraciones
Puntos de colocación	700
Parámetros estimados	ϵ, τ, α

5.4. Reproducibilidad y control de versiones

El repositorio público contiene 13 notebooks finales, archivos de configuración, código modular y pruebas automáticas. Los datos HCP crudos, modelos binarios y archivos volumétricos se excluyeron por tamaño y condiciones de uso. Dos pruebas unitarias verifican el equilibrio basal y la respuesta positiva frente a un estímulo; ambas se ejecutaron correctamente en Python 3.11.

6. Diseño experimental y métricas

6.1. Validación sintética

Para cada señal sintética, el segundo bloque se mantuvo como conjunto de prueba. Los tres modelos recibieron la misma partición. Se evaluaron RMSE, MAE, R^2 y correlación de Pearson de la señal retenida. Para la HRF se utilizaron RMSE, R^2 , correlación, error de amplitud máxima y error en tiempo al pico. En la PINN también se calcularon errores relativos de ϵ , τ y α .

El diseño pareado permitió aplicar una prueba de Friedman por nivel de ruido y comparaciones de Wilcoxon con corrección de Holm. Los tamaños de efecto se expresaron mediante correlación biserial por rangos.

6.2. Evaluación real bidireccional

Cada escenario real contiene dos bloques. Se realizaron dos direcciones:

1. entrenar en bloque 1 y evaluar en bloque 2;
2. entrenar en bloque 2 y evaluar en bloque 1.

Con cuatro escenarios se obtuvieron ocho experimentos por modelo. La métrica primaria fue RMSE fuera de muestra. Además, se estudió la brecha de generalización definida como RMSE de prueba menos RMSE de entrenamiento.

6.3. Consistencia fisiológica

Para cada escenario se compararon las HRF y parámetros estimados desde bloques distintos. La consistencia de HRF se cuantificó mediante RMSE y correlación de Pearson. Para los parámetros se utilizó la diferencia porcentual simétrica.

7. Resultados sintéticos

7.1. Reconstrucción fuera de muestra

La PINN obtuvo el menor RMSE en los tres niveles de ruido. El desempeño se mantuvo estable al reducir la SNR, mientras que la MLP se deterioró con mayor intensidad y el GLM mantuvo un error alto asociado a la discrepancia entre la HRF canónica y la dinámica generadora.




Figura 2: RMSE de reconstrucción del segundo bloque sintético. Los puntos representan medias y las barras la variabilidad entre instancias.

Cuadro 3: Desempeño medio de la PINN en datos sintéticos.

SNR	RMSE prueba	R^2 prueba	RMSE HRF	R^2 HRF
10	0,0577 $\pm$ 0,0234	0,9922	0,0124	0,9923
5	0,0655 $\pm$ 0,0263	0,9900	0,0139	0,9902
2	0,0800 $\pm$ 0,0428	0,9836	0,0181	0,9826

7.2. Recuperación de la HRF

La MLP reconstruyó adecuadamente los bloques largos, pero presentó errores elevados al evaluarse con el evento estandarizado de 1 s. Esto indica que el ajuste de un patrón de bloques no garantiza

la identificación de una respuesta hemodinámica generalizable. La PINN, en cambio, recuperó la HRF con errores cercanos a 0,01–0,02 puntos porcentuales BOLD.




Figura 3: RMSE de recuperación de la HRF sintética.

7.3. Recuperación de parámetros

El parámetro α fue el más estable. Los errores medios de ϵ aumentaron desde 7,1 % en SNR 10 hasta 10,5 % en SNR 2. τ presentó la mayor variabilidad, con errores medios entre 9,9 % y 14,3 %.




Figura 4: Error relativo de los parámetros fisiológicos inferidos por la PINN.

7.4. Comparaciones estadísticas

Las pruebas de Friedman fueron significativas para las métricas de señal y HRF. Las comparaciones de Wilcoxon con corrección de Holm mostraron ventajas significativas de la PINN frente al GLM y la MLP. La reducción media del RMSE de señal respecto del GLM fue 85,8 %, 84,0 % y 81,0 % para SNR 10, 5 y 2, respectivamente. Frente a la MLP, las reducciones fueron 26,0 %, 35,3 % y 60,7 %.

8. Resultados en datos reales

8.1. Desempeño agregado

Cuadro 4: Rendimiento fuera de muestra en los ocho experimentos reales.

Modelo	RMSE medio	RMSE mediano	R^2 medio	Pearson medio	Ganadores
PINN	0,5019	0,5197	0,1525	0,7540	4/8
GLM	0,5538	0,5387	0,0346	0,4604	2/8
MLP	0,5646	0,5549	-0,1418	0,7109	2/8

La PINN alcanzó el menor RMSE medio y mediano. Ganó cuatro evaluaciones, mientras que GLM y MLP ganaron dos cada uno. No obstante, la ventaja no fue uniforme en todos los escenarios.




Figura 5: RMSE fuera de muestra de GLM, MLP y PINN en las ocho direcciones reales.

8.2. Pruebas estadísticas

La prueba de Friedman no detectó diferencias globales en RMSE, MAE o R^2 . Para correlación de Pearson sí se observaron diferencias entre modelos.

Cuadro 5: Pruebas de Friedman en datos reales.

Métrica	χ^2	p
RMSE	3,000	0,2231
MAE	3,250	0,1969
R^2	3,000	0,2231
Pearson r	9,750	0,0076

Las comparaciones de Pearson mostraron que MLP superó al GLM ($p_{\text{Holm}} = 0,0234$) y PINN superó al GLM ($p_{\text{Holm}} = 0,0313$). No hubo diferencia significativa entre MLP y PINN ($p_{\text{Holm}} = 0,0781$).

8.3. Brecha de generalización

La MLP presentó el menor error de entrenamiento, pero la mayor diferencia entre entrenamiento y prueba. La brecha media fue aproximadamente 0,293 puntos porcentuales BOLD para MLP, 0,099 para PINN y 0,063 para GLM.




Figura 6: Brecha de generalización definida como RMSE de prueba menos RMSE de entrenamiento.

8.4. Consistencia de HRF y parámetros

Las HRF estimadas desde bloques distintos tuvieron correlación media 0,958 y RMSE medio 0,0428 puntos porcentuales BOLD. La forma temporal fue consistente, aunque la amplitud varió en algunos escenarios.

La diferencia simétrica media fue 11,17 % para α , 34,97 % para ϵ y 40,48 % para τ . Por tanto, α fue el parámetro más estable y τ el menos identificable con un solo bloque.

8.5. Relación con la repetibilidad de los bloques

No se observó una asociación concluyente entre correlación de bloques y RMSE. Este análisis utiliza solo cuatro escenarios y debe considerarse exploratorio.




Figura 7: Relación exploratoria entre repetibilidad de los bloques y error predictivo medio.

9. Discusión

9.1. Interpretación de la validación sintética

La validación sintética demuestra que la formulación inversa puede recuperar tanto la respuesta BOLD retenida como una HRF operacional y parámetros generadores cuando los supuestos del modelo son correctos. La superioridad frente al GLM se explica por la discrepancia entre una HRF canónica fija y la dinámica específica utilizada para generar los datos. La ventaja frente a la MLP es particularmente relevante: la MLP reproduce bien los bloques de entrenamiento, pero su respuesta frente a un evento breve no coincide con la HRF verdadera. La restricción fisiológica reduce el conjunto de soluciones compatibles con los datos.

9.2. Interpretación de los datos reales

En el sujeto real, la PINN presentó el mejor error promedio, pero no una superioridad estadística en RMSE. Este resultado es coherente con la mayor complejidad del fMRI real: los bloques pueden diferir por variabilidad neuronal, vascular, de movimiento y de línea base. Además, el modelo Balloon-Windkessel es una simplificación y no representa todos los mecanismos que afectan la señal.

La MLP mostró una correlación temporal alta, pero también una brecha de generalización considerable. Esto sugiere que aprovechó con mayor intensidad particularidades del bloque de entrenamiento. La PINN mantuvo un compromiso entre ajuste, generalización e interpretabilidad.

9.3. Identificabilidad

La alta consistencia de forma de la HRF no implica que todos los parámetros sean identificables. Distintas combinaciones de ϵ , τ y α pueden generar respuestas BOLD similares. τ fue especialmente variable en datos reales. Por ello, los parámetros se denominan *efectivos*: dependen de las constantes fijadas, la ROI, el preprocesamiento, las cotas y la ventana analizada.

9.4. Limitaciones

- La aplicación real se restringió a un sujeto y cuatro combinaciones corrida-ROI.
- Existen solo ocho comparaciones pareadas reales, lo que limita la potencia estadística.
- La validación real no dispone de HRF ni parámetros verdaderos.
- Parte de los parámetros fisiológicos se mantuvo fija.
- No se modeló explícitamente autocorrelación residual en la inferencia del GLM.
- Las ROI esféricas no capturan toda la heterogeneidad espacial de M1.
- La estimación depende de la calidad de la regresión de confusores y de la definición de ventanas.

9.5. Trabajo futuro

El siguiente paso natural es ampliar el análisis a múltiples sujetos, incorporar una estrategia jerárquica o poblacional para los parámetros y evaluar sensibilidad a las constantes fisiológicas. También sería pertinente usar estimación de incertidumbre, comparar con deconvolución flexible y explorar PINNs con pesos de pérdida adaptativos.

10. Conclusiones

Se desarrolló una PINN inversa para estimar estados neurovasculares, una HRF operacional y parámetros efectivos del modelo Balloon-Windkessel. La reformulación que separa el entrenamiento de la predicción mediante integración ODE independiente fue fundamental para evitar soluciones físicamente blandas con baja generalización.

En 60 experimentos sintéticos, la PINN recuperó la señal, la HRF y los parámetros con alta precisión incluso bajo ruido elevado, y superó significativamente al GLM y a la MLP. Estos resultados validan la metodología en un entorno con ground truth conocido.

En los datos reales del sujeto HCP 100206, la PINN obtuvo el menor RMSE medio y ganó cuatro de ocho evaluaciones. Las diferencias de error no fueron estadísticamente significativas, pero PINN

y MLP presentaron una correlación temporal superior al GLM. La MLP mostró la mayor brecha de generalización, mientras que la PINN produjo HRF altamente consistentes en forma.

En conjunto, la incorporación de conocimiento fisiológico mejoró la identificación y generalización en datos controlados y ofreció una representación interpretable en fMRI real. Sin embargo, la estimación de parámetros individuales, en especial τ , requiere más datos y análisis de incertidumbre antes de atribuir significado fisiológico o clínico directo.

A. Reproducibilidad

El código y los resultados livianos se encuentran en el repositorio <https://github.com/Vale-Montoya/PINN-HRF-fMRI>. La estructura incluye:

- notebooks de preparación, pilotos, lotes y análisis estadístico;
- código modular en `src/pinn_hrf`;
- configuraciones de la PINN;
- resultados sintéticos y reales;
- pruebas unitarias del modelo Balloon–Windkessel;
- código fuente de este informe.

Los archivos fMRI volumétricos, datos crudos HCP y modelos binarios no se versionan. Para verificar el modelo fisiológico se ejecuta:

```
python -m pytest
```

La ejecución local validada produjo dos pruebas aprobadas.

Referencias

- [1] R. B. Buxton, E. C. Wong y L. R. Frank. Dynamics of blood flow and oxygenation changes during brain activation: The balloon model. *Magnetic Resonance in Medicine*, 39(6):855–864, 1998. doi:10.1002/mrm.1910390602.
- [2] K. J. Friston, P. Fletcher, O. Josephs, A. Holmes, M. D. Rugg y R. Turner. Event-related fMRI: Characterizing differential responses. *NeuroImage*, 7(1):30–40, 1998. doi:10.1006/nimg.1997.0306.
- [3] G. H. Glover. Deconvolution of impulse response in event-related BOLD fMRI. *NeuroImage*, 9(4):416–429, 1999. doi:10.1006/nimg.1998.0419.
- [4] K. J. Friston, A. Mechelli, R. Turner y C. J. Price. Nonlinear responses in fMRI: The Balloon model, Volterra kernels, and other hemodynamics. *NeuroImage*, 12(4):466–477, 2000. doi:10.1006/nimg.2000.0630.
- [5] M. Raissi, P. Perdikaris y G. E. Karniadakis. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378:686–707, 2019. doi:10.1016/j.jcp.2018.10.045.
- [6] D. C. Van Essen, S. M. Smith, D. M. Barch, T. E. J. Behrens, E. Yacoub y K. Ugurbil. The WU-Minn Human Connectome Project: An overview. *NeuroImage*, 80:62–79, 2013. doi:10.1016/j.neuroimage.2013.05.041.
- [7] M. F. Glasser, S. N. Sotiropoulos, J. A. Wilson y colaboradores. The minimal preprocessing pipelines for the Human Connectome Project. *NeuroImage*, 80:105–124, 2013. doi:10.1016/j.neuroimage.2013.04.127.
- [8] D. M. Barch, G. C. Burgess, M. P. Harms y colaboradores. Function in the Human Connectome: Task-fMRI and individual differences in behavior. *NeuroImage*, 80:169–189, 2013. doi:10.1016/j.neuroimage.2013.05.033.
- [9] A. Paszke, S. Gross, F. Massa y colaboradores. PyTorch: An imperative style, high-performance deep learning library. En *Advances in Neural Information Processing Systems*, volumen 32, 2019.
- [10] S. Holm. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2):65–70, 1979.